



APRENDIZAJE DE MÁQUINA

PROBABILIDAD

AGENDA

01 Repaso Probabilidad

Introducción, variables aleatorias, Teorema de Bayes





PROBABILIDAD

DEFINICIONES

PROBABILIDAD CONDICIONADA

PROBABILIDAD

DEFINICIONES



Espacio muestral Ω : conjunto de todas los resultados ω de un experimento aleatorio. Donde cada $\omega \in \Omega$ se define como una descripción completa del estado real del mundo después del experimento.

Espacio de eventos \mathcal{F} : conjunto cuyos elementos $A \in \mathcal{F}$ (denominados eventos) son subconjuntos de Ω .

Medida probabilística: es una función $P: \mathcal{F} \rightarrow \mathbb{R}$ que satisface los **3 axiomas de probabilidad**.

- 1) $P(A) \geq 0, \forall A \in \mathcal{F}$
- 2) $P(\Omega) = 1$
- 3) Sí A_1, A_2, \dots son eventos disjuntos por lo tanto:

$$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$$

PROBABILIDAD

DEFINICIONES



Ejemplo: realizamos el experimento de lanzar 2 monedas al aire.

- **Espacio muestral Ω :**
- **Evento E :** que en la 1° moneda salga cara
- **Medida probabilística P :** la probabilidad del evento E (suponiendo que cada resultado es igualmente probable).

PROBABILIDAD

DEFINICIONES



Respuesta: realizamos el experimento de lanzar 2 monedas al aire.

- Espacio muestral Ω :

$$S = \{(H, H), (H, T), (T, H), (T, T)\}$$

- Evento E : que en la 1° moneda salga cara

$$E = \{(H, H), (H, T)\}$$

- Medida probabilística P : la probabilidad del evento E sería.


$$P(E) = \frac{2}{4} = \frac{1}{2}$$

PROBABILIDAD

PROPIEDADES



1 If $A \subseteq B \implies P(A) \leq P(B)$.





PROBABILIDAD

PROPIEDADES




2 $P(A \cap B) \leq \min(P(A), P(B)).$

$P(A \cap B) = P(A)$



$P(A \cap B) < P(A)$
 $P(A \cap B) < P(B)$

$P(A \cap B) = P(B)$




PROBABILIDAD

PROPIEDADES



3 (Union Bound) $P(A \cup B) \leq P(A) + P(B)$.

$$P(A \cup B) = P(A)$$




B

A

$$P(A \cup B) = P(A) + P(B)$$

$$P(A \cup B) = P(B)$$



A


B

PROBABILIDAD

PROPIEDADES



4 $P(\Omega \setminus A) = 1 - P(A).$




PROBABILIDAD

PROPIEDADES



5 (Law of Total Probability) If A_1, \dots, A_k are a set of disjoint events such that $\bigcup_{i=1}^k A_i = \Omega$, then $\sum_{i=1}^k P(A_i) = 1$.



PROBABILIDAD

PROBABILIDAD CONDICIONADA




Probabilidad condicionada: la medida de probabilidad $P(A/B)$ define la probabilidad de un evento A después de observar la ocurrencia del evento B con una probabilidad $P(B) \neq 0$.

$$P(A|B) \triangleq \frac{P(A \cap B)}{P(B)}$$

Independencia: se dice que 2 eventos A y B son independientes si la observación del evento de B no afecta a la probabilidad del evento A .

$$P(A/B) = P(A)$$

$$\therefore P(A \cap B) = P(A)P(B)$$



PROBABILIDAD

PROBABILIDAD CONDICIONADA



Ejemplo: una moneda es lanzada al aire 2 veces. Suponiendo que todos los resultados son equi-probables, ¿cuál es la probabilidad de que ambos lanzamientos hayan resultado en cara (H) dado que

- a) la 1° moneda resultó en H ?
- b) al menos un lanzamiento resultó en H ?

PROBABILIDAD

PROBABILIDAD CONDICIONADA



Respuestas:

a) $P(\text{ambos } H / 1^{\circ} H) = \frac{1}{2}$

b) $P(\text{ambos } H / \text{al menos } 1 H) = \frac{1}{3}$



PROBABILIDAD

VARIABLES ALEATORIAS

PROBABILIDAD

VARIABLES ALEATORIAS



Muchas veces, **NO** nos importan los **resultados** $\omega \in \Omega$ de un experimento. Lo que nos **importa** son **funciones** de estos resultados $X(\omega)$.


Formalmente una **variable aleatoria** es una función:

$$X: \Omega \rightarrow \mathbb{R}$$

| Variables aleatorias discretas | Variables aleatorias continuas |
|--|--|
| $X(\omega)$ puede tomar un valor finito de valores . | $X(\omega)$ puede tomar un valor infinito de valores . |
| $P(X = k) := P(\{\omega: X(\omega) = k\})$ | $P(a \leq X \leq b) := P(\{\omega: (a \leq X(\omega) \leq b)\})$ |
| Ejemplo: $X(\omega)$ es el número de caras que ocurren en una secuencia de lanzamientos ω . | Ejemplo: $X(\omega)$ es el tiempo de decaimiento radioactivo de una partícula. |

PROBABILIDAD

FUNCIONES DE PROBABILIDAD




Se necesitan diferentes **medidas** de **probabilidad** cuando se plantean **variables aleatorias**. Para esto se definen **funciones** de **probabilidad**:

1. Función de Distribución Acumulada (discreta y continua) → CDF.
2. Función de Masa de Probabilidad (discretas) → PMF.
3. Función de Densidad de Probabilidad (continuas) → PDF.

NOTA: cuando la variable aleatoria X toma un valor específico, se denota con minúscula x .

PROBABILIDAD

FUNCIÓN DE DISTRIBUCIÓN ACUMULADA



La Función de Distribución Acumulada es una función $F_X: \mathbb{R} \rightarrow [0,1]$ que especifica la medida de probabilidad como:

$$F_X(x) \triangleq P(X \leq x).$$

Intuitivamente se puede decir que esta función define las probabilidades de todos los eventos $A_i \in \Omega$ cuando $x \rightarrow \infty$

Propiedades:

$$0 \leq F_X(x) \leq 1.$$

$$\lim_{x \rightarrow -\infty} F_X(x) = 0.$$

$$\lim_{x \rightarrow \infty} F_X(x) = 1.$$

$$x \leq y \implies F_X(x) \leq F_X(y).$$

PROBABILIDAD

FUNCIÓN DE MASA DE PROBABILIDAD



La Función de Masa de Probabilidad **asigna una medida de probabilidad** a cada **valor** que puede **tomar** la **variable** aleatoria X .

$$p_X(x) \triangleq P(X = x).$$

Propiedades:

$$0 \leq p_X(x) \leq 1.$$

$$\sum_{x \in \text{Val}(X)} p_X(x) = 1.$$

$$\sum_{x \in A} p_X(x) = P(X \in A).$$

Donde $\text{Val}(X)$ representa todos los posibles valores que puede tomar

PROBABILIDAD

FUNCIÓN DE DENSIDAD DE PROBABILIDAD



La Función de Densidad de Probabilidad **asigna una medida de probabilidad** a cada **valor** que puede **tomar** la **variable** aleatoria X en un **intervalo continuo**.

Formalmente se define como la derivada de la Función de Distribución Acumulada:

$$f_X(x) \triangleq \frac{dF_X(x)}{dx}.$$

Dicha función **puede no existir**.

Propiedades:

$$f_X(x) \geq 0.$$

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

$$\int_{x \in A} f_X(x) dx = P(X \in A).$$

PROBABILIDAD


EJEMPLOS PRÁCTICOS



Ejemplo:

Suponiendo que X es una variable aleatoria continua y su PDF está descrita por:

$$f_X(t) = \frac{1}{b-a}, \forall t \in [a, b]$$
$$f_X(t) = 0 \text{ de otra forma}$$



Calcule la gráfica de su CDF.

PROBABILIDAD

EJEMPLOS PRÁCTICOS




Respuesta:

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t) dx$$

$$F_X(x) = \int_{-\infty}^a \frac{1}{b-a} dx + \int_a^x \frac{1}{b-a} dx + \int_x^b \frac{1}{b-a} dx$$

$$F_X(x) = 0 + \frac{x}{b-a} + 0$$



PROBABILIDAD

VALOR ESPERADO



Suponemos que X es una **variable aleatoria discreta** con una **PMF** $p_X(x)$ y $g: \mathbb{R} \rightarrow \mathbb{R}$ una función arbitraria. En este caso, $g(X)$ se considera una **variable aleatoria**, por lo que se define al **valor esperado** de $g(X)$ como:

$$E[g(X)] \triangleq \sum_{x \in \text{Val}(X)} g(x)p_X(x).$$

PROBABILIDAD

VALOR ESPERADO



Suponemos que X es una **variable aleatoria continua** con una **PDF** $f_X(x)$, por lo tanto el **valor esperado** de $g(X)$ sería:

$$E[g(X)] \triangleq \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

PROBABILIDAD

VALOR ESPERADO



Intuitivamente lo que se calcula en el **valor esperado** es un “**promedio ponderado**” de los **valores de $g(x)$** donde los **pesos** están dados ya sea **por $f_X(x)$ o $p_X(x)$** .

NOTA: cuando $g(x) = x$ el valor esperado de la variable aleatoria X sería la **media aritmética**.

Propiedades:

$E[a] = a$ for any constant $a \in \mathbb{R}$.

$E[af(X)] = aE[f(X)]$ for any constant $a \in \mathbb{R}$.

(Linearity of Expectation) $E[f(X) + g(X)] = E[f(X)] + E[g(X)]$.

For a discrete random variable X , $E[1\{X = k\}] = P(X = k)$.

PROBABILIDAD

V A R I A N Z A



La **varianza** de una **variable aleatoria** X es la **medida** de como está **concentrada** la **distribución** de la **variable aleatoria** X **alrededor** de la **media**.

$$Var[X] \triangleq E[(X - E(X))^2]$$

PROBABILIDAD

V A R I A N Z A



TAREA:

Demostrar la siguiente igualdad.

$$E[(X - E(X))^2] = E[X^2] - E[X]^2$$

PROBABILIDAD

V A R I A N Z A



Propiedades:

$Var[a] = 0$ for any constant $a \in \mathbb{R}$.

$Var[af(X)] = a^2 Var[f(X)]$ for any constant $a \in \mathbb{R}$.

PROBABILIDAD

VALOR ESPERADO



Ejemplo:

Calcular la media y la varianza de una variable aleatoria X con PDF $f_X(x) = 1, \forall x \in [0,1], 0$ en otro rango.

PROBABILIDAD

V A L O R E S P E R A D O



Respuesta:

$$E[X] = \frac{1}{2}$$

$$Var[X] = \frac{1}{12}$$



AE

PROBABILIDAD

EJEMPLOS DE VARIABLES

ALEATORIAS

PROBABILIDAD

EJEMPLOS DE VARIABLES ALEATORIAS






Discretas:

BERNOULLI
$$p(x) = \begin{cases} p & \text{if } x = 1 \\ 1 - p & \text{if } x = 0 \end{cases}$$

BINOMIAL
$$p(x) = \binom{n}{x} p^x (1 - p)^{n-x}$$


GEOMÉTRICA
$$p(x) = p(1 - p)^{x-1}$$

POISSON
$$p(x) = e^{-\lambda} \frac{\lambda^x}{x!}$$



PROBABILIDAD

EJEMPLOS DE VARIABLES ALEATORIAS



Continuas:

UNIFORME

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b \\ 0 & \text{otherwise} \end{cases}$$

EXPONENCIAL







$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{if } x \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

NORMAL

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

PROBABILIDAD

EJEMPLOS DE VARIABLES ALEATORIAS



PROBABILIDAD

EJEMPLOS DE VARIABLES ALEATORIAS



TAREA:

Obtener la media y varianza de las 4 distribuciones discretas.

| Distribution | PDF or PMF | Mean | Variance |
|--------------------|---|---------------|-------------------|
| $Bernoulli(p)$ | $\begin{cases} p, & \text{if } x = 1 \\ 1 - p, & \text{if } x = 0. \end{cases}$ | p | $p(1 - p)$ |
| $Binomial(n, p)$ | $\binom{n}{k} p^k (1 - p)^{n-k}$ for $0 \leq k \leq n$ | np | npq |
| $Geometric(p)$ | $p(1 - p)^{k-1}$ for $k = 1, 2, \dots$ | $\frac{1}{p}$ | $\frac{1-p}{p^2}$ |
| $Poisson(\lambda)$ | $e^{-\lambda} \lambda^x / x!$ for $k = 1, 2, \dots$ | λ | λ |



AE

PROBABILIDAD

DOS VARIABLES ALEATORIAS

PROBABILIDAD

DISTRIBUCIONES CONJUNTAS Y MARGINALES ACUMULADAS



Si se quieren conocer los **valores** de **dos variables** aleatorias X y Y de manera **simultánea**, se necesita la **distribución de conjunta acumulada** de X y Y :

$$F_{XY}(x, y) = P(X \leq x, Y \leq y)$$

Las **funciones de distribución** $F_X(x)$ y $F_Y(y)$ se denominan funciones de **distribución acumulada marginal**

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y) dy$$
$$F_Y(y) = \lim_{x \rightarrow \infty} F_{XY}(x, y) dx.$$

PROBABILIDAD

DISTRIBUCIONES CONJUNTAS Y MARGINALES ACUMULADAS



Propiedades:

$$0 \leq F_{XY}(x, y) \leq 1.$$

$$\lim_{x, y \rightarrow \infty} F_{XY}(x, y) = 1.$$

$$\lim_{x, y \rightarrow -\infty} F_{XY}(x, y) = 0.$$

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$



PROBABILIDAD

FUNCIONES DE MASA CONJUNTAS Y MARGINALES

Si X y Y son **variables aleatorias discretas**, la **función de masa de probabilidad conjunta** $p_{XY}: \mathbb{R} \times \mathbb{R} \rightarrow [0,1]$ está definida por:

$$p_{XY}(x, y) = P(X = x, Y = y).$$

Propiedades:

$$0 \leq P_{XY}(x, y) \leq 1 \text{ for all } x, y.$$

$$\sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} P_{XY}(x, y) = 1.$$

PROBABILIDAD

FUNCIONES DE MASA CONJUNTAS Y MARGINALES




Las **funciones de masa de probabilidad marginales** de X y Y están definidas por:

$$p_X(x) = \sum_y p_{XY}(x, y).$$

$$p_Y(y) = \sum_x p_{XY}(x, y)$$

PROBABILIDAD

FUNCIONES DE DENSIDAD CONJUNTAS Y MARGINALES



Si X y Y son **variables aleatorias continuas**, con una **distribución conjunta** F_{XY} **diferenciable** en **todo** el espacio, se define la **función de densidad de probabilidad** como:

$$f_{XY}(x, y) = \frac{\partial^2 F_{XY}(x, y)}{\partial x \partial y}.$$

$$\iint_{x \in A} f_{XY}(x, y) dx dy = P((X, Y) \in A).$$

PROBABILIDAD

FUNCIONES DE DENSIDAD CONJUNTAS Y MARGINALES




Las **funciones de densidad de probabilidad marginales** de X y Y serían:

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x, y) dx$$

PROBABILIDAD

FUNCIONES DE DENSIDAD CONJUNTAS Y MARGINALES



Ejemplo:

La **función de densidad conjunta** de X y Y está dada por:

$$f(x, y) = \begin{cases} 2e^{-x}e^{-2y} & 0 < x < \infty, \quad 0 < y < \infty \\ 0 & \text{de otra forma} \end{cases}$$

Calcular $P(X > 1, Y < 1)$

PROBABILIDAD

FUNCIONES DE DENSIDAD CONJUNTAS Y MARGINALES



Respuesta:

$$P(X > 1, Y < 1) = e^{-1}(1 - e^{-2})$$

PROBABILIDAD

DISTRIBUCIONES CONDICIONADAS



La **función de masa de probabilidad condicionada** en el caso discreto:

$$p_{Y|X}(y|x) = \frac{p_{XY}(x, y)}{p_X(x)}$$

La **función de densidad de probabilidad condicionada** en el caso continuo:

$$f_{Y|X}(y|x) = \frac{f_{XY}(x, y)}{f_X(x)}$$

PROBABILIDAD

VALOR ESPERADO



Variables discretas:


$$E[g(X, Y)] \triangleq \sum_{x \in \text{Val}(X)} \sum_{y \in \text{Val}(Y)} g(x, y) p_{XY}(x, y).$$

Variables continuas:

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{XY}(x, y) dx dy.$$

PROBABILIDAD

C O V A R I A N Z A



Para estudiar la relación de 2 variables aleatorias se utiliza la covarianza.

$$Cov[X, Y] \triangleq E[(X - E[X])(Y - E[Y])]$$

Cuando $Cov[X, Y] = 0$ se dice que **X** y **Y** no están correlacionadas.

TAREA:

Demostrar que:

$$Cov[X, Y] = E[XY] - E[X]E[Y]$$



PROBABILIDAD

MÚLTIPLES VARIABLES

ALEATORIAS

PROBABILIDAD

D I S T R I B U C I O N E S



Suponiendo que se tienen n **variables aleatorias continuas** X_1, X_2, \dots, X_n se tienen las siguientes **distribuciones**:

Función de probabilidad conjunta acumulada

$$F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

Función de densidad de probabilidad conjunta

$$f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \frac{\partial^n F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n)}{\partial x_1 \dots \partial x_n}$$

PROBABILIDAD

D I S T R I B U C I O N E S



Suponiendo que se tienen n **variables aleatorias continuas** X_1, X_2, \dots, X_n se tienen las siguientes **distribuciones**:

Función de densidad de probabilidad marginal de X_1

$$f_{X_1}(X_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) dx_2 \dots dx_n$$

Función de densidad de probabilidad condicionada

$$f_{X_1|X_2, \dots, X_n}(x_1|x_2, \dots, x_n) = \frac{f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n)}{f_{X_2, \dots, X_n}(x_2, \dots, x_n)}$$

PROBABILIDAD

REGLA DEL PRODUCTO



La función de **densidad de probabilidad conjunta** se puede expresar como el **producto** de las **probabilidades condicionadas**:

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= f(x_n | x_1, x_2, \dots, x_{n-1}) f(x_1, x_2, \dots, x_{n-1}) \\ &= f(x_n | x_1, x_2, \dots, x_{n-1}) f(x_{n-1} | x_1, x_2, \dots, x_{n-2}) f(x_1, x_2, \dots, x_{n-2}) \\ &= \dots = f(x_1) \prod_{i=2}^n f(x_i | x_1, \dots, x_{i-1}). \end{aligned}$$

PROBABILIDAD

I N D E P E N D E N C I A



La **propiedad de independencia** se **generaliza** para n variables aleatorias X_1, X_2, \dots, X_n :

$$f(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n).$$

Se dice que k **eventos** A_1, A_2, \dots, A_k son **mutuamente independientes** si para **cualquier subconjunto** $S \subseteq \{1, 2, \dots, k\}$ se tiene que:

$$P(\cap_{i \in S} A_i) = \prod_{i \in S} P(A_i).$$



AI

PROBABILIDAD

VECTORES ALEATORIOS

PROBABILIDAD

VECTORES ALEATORIOS




Cuando se trabaja con n **variables aleatorias** es conveniente **representarlas** utilizando un **vector**, denominado **vector aleatorio**, que realiza un **mapeo de** $\Omega \rightarrow \mathbb{R}^n$:

$$X = [X_1 \ X_2 \ \dots \ X_n]^T$$

PROBABILIDAD

V A L O R E S P E R A D O



Se presenta el **cálculo** del **valor esperado** para n **variables** aleatorias **continuas** en donde se tiene una **función** de **ponderación** $g(x_1, x_2, \dots, x_n)$ y una **función** de **densidad** de **probabilidad** $f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n)$.

$$E[g(X)] = \int_{\mathbb{R}^n} g(x_1, x_2, \dots, x_n) f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n,$$



PROBABILIDAD

TEOREMA DE BAYES

PROBABILIDAD

DERIVACIÓN DEL TEOREMA



Suponiendo que se tienen **2 variables aleatorias X y Y discretas** se puede escribir la probabilidad condicionada como:

$$p(Y/X) = \frac{p(X, Y)}{p(X)}$$

Aplicando la **propiedad simétrica** $p(Y, X) = p(X, Y)$ y la **regla del producto** de probabilidad $p(X, Y) = p(X/Y)p(Y)$ se tiene que:

$$p(Y/X) = \frac{p(X/Y)p(Y)}{p(X)}$$

PROBABILIDAD

DERIVACIÓN DEL TEOREMA



Además se sabe por la **regla** de la **suma** de **probabilidades**, que la **probabilidad** de un **evento** es igual a la suma de las intersecciones de ese **evento** con todos los demás **eventos**:

$$p(X) = \sum_Y p(X, Y) = \sum_Y p(X/Y) p(Y)$$

$$p(Y/X) = \frac{p(X/Y)p(Y)}{\sum_Y p(X/Y) p(Y)}$$

PROBABILIDAD

APLICACIÓN DEL TEOREMA



Ejemplo:

2. Question: A diagnostic test has a probability 0.95 of giving a positive result when applied to a person suffering from a certain disease, and a probability 0.10 of giving a (false) positive when applied to a non-sufferer. It is estimated that 0.5 % of the population are sufferers. Suppose that the test is now administered to a person about whom we have no relevant information relating to the disease (apart from the fact that he/she comes from this population). Calculate the following probabilities:

- (a) that the test result will be positive;
- (b) that, given a positive result, the person is a sufferer;

PROBABILIDAD

APLICACIÓN DEL TEOREMA



Respuesta:

$$(a) \quad \mathbf{P}(T) = \mathbf{P}(T|S)\mathbf{P}(S) + \mathbf{P}(T|S')\mathbf{P}(S') = (0.95 \times 0.005) + (0.1 \times 0.995) = 0.10425.$$

$$(b) \quad \mathbf{P}(S|T) = \frac{\mathbf{P}(T|S)\mathbf{P}(S)}{\mathbf{P}(T|S)\mathbf{P}(S) + \mathbf{P}(T|S')\mathbf{P}(S')} = \frac{0.95 \times 0.005}{(0.95 \times 0.005) + (0.1 \times 0.995)} = 0.0455.$$

PROBABILIDAD

EXPLICANDO EL TEOREMA



Interpretando el Teorema de Bayes:

$$\begin{array}{c} \text{Posterior} \\ \downarrow \\ P(A|B) \end{array} = \frac{\begin{array}{c} \text{Likelihood} \\ \downarrow \\ P(B|A) \end{array} * \begin{array}{c} \text{Prior} \\ \downarrow \\ P(A) \end{array}}{\begin{array}{c} \uparrow \\ P(B) \\ \text{Evidence} \end{array}}$$

1. **Prior:** son las “**creencias**” que tenemos sobre como se distribuye la variable aleatoria **A** antes de obtener **evidencia B**.
2. **Posterior:** captura la **distribución** de la **variable aleatoria A** después de haber recopilado la **evidencia B**.
3. **Likelihood:** expresa la **probabilidad** de que nuestras **creencias** (distribución de **A**) sean ciertas acorde a la evidencia B.

PROBABILIDAD

EXPLICANDO EL TEOREMA



$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

Leer páginas **21 – 23** del libro “***Pattern Recognition and Machine Learning***” de Christopher Bishop, 1º Edición.